

Slovenská technická univerzita v Bratislave  
Fakulta informatiky a informačných technológií

FIIT-182905-105345

**Bc. Monika Zjavková**

**Predikčný model na stanovenie  
dermatotoxicity**

Prílohy

Vedúci práce: Ing. Marta Šoltésová Prnová PhD.

Máj 2025

# Dodatok A

## Inštalčná príručka

Aplikáciu je možné spustiť prostredníctvom virtuálneho prostredia, ktoré zabezpečuje izolované prostredie s vlastnými knižnicami a závislosťami. Postup inštalácie je nasledovný:

### 1. Stiahnutie zdrojového kódu

Najprv si stiahnite zdrojový kód aplikácie a prejdite do príslušného adresára v termináli.

### 2. Vytvorenie virtuálneho prostredia

V koreňovom adresári aplikácie vytvorte nové virtuálne prostredie:

```
python -m venv venv
```

### 3. Aktivácia virtuálneho prostredia

Aktivujte prostredie podľa vášho operačného systému:

*Linux/macOS:*

```
source venv/bin/activate
```

*Windows:*

```
venv\Scripts\activate
```

#### 4. Inštalácia závislostí

Po aktivácii virtuálneho prostredia nainštalujte požadované knižnice pomocou súboru `requirements.txt`:

```
pip install -r requirements.txt
```

#### 5. Spustenie aplikácie

Aplikáciu spustíte nasledovným príkazom:

```
python manage.py runserver
```

Aplikácia bude následne dostupná na adrese: <http://localhost:8000/>

# Dodatok B

## Používateľská príručka

### B.1 Predikcia podráždenia pokožky

Aplikácia umožňuje predikovať potenciál chemickej látky spôsobiť podráždenie pokožky. Užívateľské rozhranie je navrhnuté jednoducho a intuitívne. Postupujte podľa nasledujúcich krokov:

1. Spustíte aplikáciu vo webovom prehliadači. Aplikácia je dostupná na adrese `http://localhost:8000`.
2. Do vstupného poľa zadajte chemickú štruktúru vo formáte SMILES alebo zadajte CAS číslo danej zlúčeniny.
3. Stlačte tlačidlo **Predict** pre spustenie predikcie.
4. Po predikcii sa zobrazia nasledujúce informácie:
  - **Výsledok predikcie:** Označenie látky ako **Irritant** alebo **Non-Irritant**.
  - **Dôveryhodnosť modelu (Trust Score)** v percentách.
  - **Vizualizácia molekuly** na základe SMILES.

- **Chemické informácie:** názov zlúčeniny, molekulový vzorec, SMILES reťazec a CAS číslo.
- **Informácie o datasete:** zdroj údajov, veľkosť datasetu, formát dát a validácia.
- **Graf ROC krivky** modelu.
- **Hodnoty SHAP:** vplyv jednotlivých modelov (KNN, Random Forest, XGBoost, SVM, Decision Tree) na výstupnú predikciu.

# Dodatok C

## Technická dokumentácia

Táto kapitola popisuje technické aspekty riešenia diplomovej práce, vrátane architektúry systému, štruktúry súborov, použitých technológií a implementačných rozhodnutí. Výsledný softvér pozostáva z dvoch samostatných častí:

1. fáza vývoja modelov, ktorá zahŕňa spracovanie dát, výber príznakov, tréningovanie a optimalizáciu modelov pomocou Jupyter notebookov,
2. produkčná fáza – webová aplikácia postavená na Django frameworku, ktorá poskytuje jednoduché a prístupné rozhranie na predikciu dermatotoxicity chemických látok pomocou uloženého modelu.

### C.1 Fáza vývoja modelov (offline spracovanie)

Tréningová časť bola realizovaná výhradne pomocou Jupyter notebookov. Každý krok spracovania a vývoja modelu je oddelený do samostatného notebooku pre lepšiu prehľadnosť a flexibilitu.

## Použité notebooky

- `data_processing.ipynb` – načítanie datasetu, čistenie údajov, spracovanie chemických štruktúr do deskriptorov,
- `feature_selection.ipynb` – zníženie počtu príznakov pomocou korelačnej analýzy, rozptylu, LASSO a SHAP hodnôt,
- `hyperparameter_optimization_X.ipynb` – samostatné notebooky pre optimalizáciu každého modelu.
- `ensemble_model.ipynb` – porovnanie modelov, prípadne kombinácia a výber finálneho modelu na nasadenie.

## Uloženie modelu

Najlepší model bol uložený pomocou knižnice `joblib` a exportovaný do súboru, ktorý je následne použitý v produkčnej časti aplikácie.

## C.2 Webová aplikácia (Django)

Django aplikácia slúžila na nasadenie uloženého modelu. Obsahuje všetky potrebné komponenty na vizualizáciu a interpretáciu výsledkov:

- `views.py` – načítanie modelov, spracovanie vstupu, volanie predikcie, generovanie výstupov,
- `urls.py` – routovanie požiadaviek,
- `templates/` – HTML šablóny s Bootstrapom,
- `static/` – CSS, JS a statické zdroje (napr. vykreslené grafy),

- **utils/** – pomocné skripty pre spracovanie SMILES, vykresľovanie molekúl, načítanie SHAP hodnôt.

Po zadaní chemickej látky používateľom aplikácia:

1. transformuje SMILES do deskriptorov,
2. aplikuje rovnaké predspracovanie ako počas tréningu (napr. škálovanie),
3. použije uložený model na vykonanie predikcie,
4. zobrazí výsledky vrátane interpretácie (napr. SHAP grafy, vizualizácia molekuly),

## C.3 Použité knižnice

V rámci vývoja riešenia boli využité viaceré knižnice na oblasti spracovania dát, strojového učenia, vizualizácie, štatistiky a webový vývoj. V nasledujúcom prehľade sú uvedené najdôležitejšie z nich:

- **RDKit** – nástroj na výpočty a vizualizácie chemických štruktúr.
- **pandas** – knižnica na manipuláciu s dátami vo forme tabuliek (DataFrame).
- **NumPy** – základná knižnica pre numerické výpočty. Využíva sa najmä na prácu s poľami, lineárnu algebru a matematické transformácie.
- **scikit-learn** – hlavný framework pre implementáciu modelov strojového učenia. Bol použitý na trénovanie aj na metriky vyhodnocovania.
- **XGBoost** – implementácia gradient boosting algoritmu. V projekte použitá ako jeden z klasifikačných modelov.
- **SHAP** – nástroj na vysvetľovanie rozhodnutí modelov strojového učenia.



Pomocou SHAP hodnôt bola vyhodnotená dôležitosť jednotlivých deskriptorov v predikcii.

- **Optuna** – framework pre automatizovanú optimalizáciu hyperparametrov.
- **matplotlib** a **seaborn** – knižnice na vizualizáciu dát a výsledkov. Použité na generovanie grafov (ROC krivky, SHAP diagramy.)
- **joblib** – slúži na ukladanie modelov na disk, aby mohli byť neskôr načítané v produkčnej aplikácii.
- **SciPy** – doplnková knižnica pre štatistické výpočty (napr. distribúcie, testy normality, rozptylové analýzy).
- **Django** – webový framework v jazyku Python, použitý na vytvorenie používateľského rozhrania, prípravu logiky pre načítanie modelu, predikciu a zobrazenie výstupu.

# Dodatok D

## Časový plán práce

Táto kapitola poskytuje prehľad časového harmonogramu a hodnotí jeho realizáciu. Nasleduje rozdelenie podľa semestrov s podrobnosťami jednotlivých krokov.

### D.1 Letný semester 2023/2024

V letnom semestri som sa zameriavala na analýzu problému, návrh aplikácie a predspracovanie dát. Pracovný plán prebiehal nasledovne:

- **Týždeň 1-2:** Preštudovanie literatúry o QSAR modelovaní a predikcii dermatotoxicity.
- **Týždeň 3-4:** Písanie kapitoly o analýze problému a výbere modelov strojového učenia.
- **Týždeň 5-6:** Zoznamovanie sa s dostupnými datasetmi a ich štruktúrou (SMILES kódy, chemické deskriptory).
- **Týždeň 7-8:** Návrh architektúry aplikácie a vytvorenie úvodných diagramov

pracovných procesov.

- **Týždeň 9-10:** Predspracovanie a čistenie dát, výpočet deskriptorov pomocou RDKit.
- **Týždeň 11-12:** Písanie kapitoly o návrhu riešenia.

## D.2 Zimný semester 2024/2025

Zimný semester bol venovaný implementácii algoritmov, výberu vlastností (feature selection), optimalizácii a validácii modelov.

- **Týždeň 1-3:** Implementácia algoritmov strojového učenia (Random Forest, SVM, XGBoost).
- **Týždeň 4:** Validácia modelov na tréningových a testovacích dátach.
- **Týždeň 5-6:** Implementácia metód výberu vlastností (SHAP, filter, wrapper metódy).
- **Týždeň 7-8:** Optimalizácia hyperparametrov pomocou grid search a ďalších metód.
- **Týždeň 9:** Implementácia vizualizácie pomocou SHAP a interpretácie výsledkov.
- **Týždeň 10:** Testovanie aplikácie a identifikácia chýb v predikciách.
- **Týždeň 11:** Oprava nedostatkov a vylepšenia aplikácie.
- **Týždeň 12:** Písanie kapitoly o implementácii riešenia.

## D.3 Letný semester 2024/2025

V letnom semestri 2025 sme sa zamerali na finálne fázy diplomovej práce, ktoré zahŕňali vývoj ensemble modelov, vytvorenie webovej aplikácie, testovanie a písanie záverečných častí dokumentácie. Pracovný plán bol rozvrhnutý nasledovne:

- **Týždeň 1–2:** Návrh a implementácia ensemble prístupu — testovanie metamodelu a hlasovania na kombinovanie viacerých predikčných algoritmov.
- **Týždeň 3–5:** Vývoj backendovej časti webovej aplikácie vrátane integrácie predikčného modelu, predspracovania vstupov a výpočtu výsledkov.
- **Týždeň 6–8:** Implementácia frontendovej časti aplikácie so zameraním na používateľsky prívetivé rozhranie, vizualizáciu výstupov a zobrazovanie SHAP interpretácií.
- **Týždeň 9:** Riešenie technických a funkčných nedostatkov zistených počas vývoja a interného testovania aplikácie.
- **Týždeň 10–11:** Písanie kapitoly o webovej aplikácii a o výsledkoch ensemble prístupu vrátane grafických výstupov a diskusie.
- **Týždeň 12:** Finálne testovanie funkčnosti aplikácie, kontrola výstupov a validácia modelov v produkčnom prostredí.

## D.4 Zhodnotenie časového harmonogramu

Časový harmonogram bol navrhnutý tak, aby pokrýval všetky hlavné fázy práce od úvodného štúdia problematiky, cez analýzu a návrh riešenia až po implementáciu a validáciu modelov. Celkový plán sa ukázal byť realistický, avšak počas realizácie bolo nutné urobiť niekoľko úprav.

V letnom semestri sme sa sústredili na preštudovanie literatúry, pochopenie dostupných datasetov a návrh aplikácie. Táto fáza prebehla prevažne podľa plánu, pričom najväčšou výzvou bolo spracovanie dát a zabezpečenie ich dostatočnej kvality pre ďalšiu analýzu. Písanie kapitol o analýze problému a návrhu riešenia prebehlo bez výrazných oneskorení.

V zimnom semestri sme sa zamerali na implementáciu algoritmov strojového učenia a optimalizáciu výsledkov. Hoci bol plán všeobecne dodržaný, implementácia metód výberu vlastností (feature selection) si vyžiadala viac času, ako sa pôvodne očakávalo. Dôvodom bola potreba experimentovania s viacerými metódami (SHAP, filter a wrapper) na dosiahnutie optimálnych výsledkov. Napriek tomu sa podarilo zachovať harmonogram implementácie.

Letný semester 2025 bol zameraný na rozšírenie modelu pomocou ensemble techník a jeho integráciu do plne funkčnej webovej aplikácie. Táto fáza si vyžiadala systematické plánovanie — backend bol navrhnutý tak, aby zvládol dynamické vstupy, zatiaľ čo frontend sa sústredil na zrozumiteľnú vizualizáciu výstupov a interpretácií modelu. Rezerva v závere semestra umožnila doladiť nedostatky a sústrediť sa na kvalitu používateľskej skúsenosti.

# Dodatok E

## Opis elektronického média

Evidenčné číslo práce: FIIT-182905-105345

Digitálna zložka diplomovej práce je rozdelená nasledovne:

```
/
├── DP_Django_App
└── DP_Qsar_Models
```

DP\_Django\_App obsahuje implementáciu webovej aplikácie. DP\_Qsar\_Models obsahuje Jupyter notebooky, kde sa nachádza spracovanie dát, výber deskriptorov a optimalizácia jednotlivých modelov. Zloženie a obsah oboch priečinkov sú bližšie popísané v prílohe C.